

Roteiro do Projeto Final — Plataforma de Análise e Comparação de Apólices D&O

Grupo Insurminds · Curso InsurMinds / I2A2 [Read in English](ROTEIRO_PROJETO_FINAL.md)

Prazo: 06/10/2026 às 23h59.

Situação em 20/09/2026 — restam 16 dias. A Fase 0 venceu em 17/09 e ainda não fechou: sem a lista de campos do Paulo Henrique, as frentes B e C não começam. As demais datas do calendário abaixo seguem como estavam; se a Fase 0 escorregar muito além desta semana, elas precisam ser revistas em grupo.

O que muda em relação ao Desafio 5

Três coisas novas, e as três pesam:

Novidade	Por que exige atenção
Pitch deck (InsurMinds_Projeto_Final.pptx)	Nome de arquivo obrigatório e literal. Não é slide de apoio: é entregável avaliado
Vídeo de até 5 minutos (InsurMinds_Projeto_Final.mp4)	Precisa de produto funcionando para gravar. Se ficar para o fim, não existe
Documento de entrada não estruturado	No Desafio 5 a API devolvia números prontos. Aqui a entrada é PDF jurídico de dezenas de páginas

E uma mudança de natureza: **esta é a avaliação final do curso**. Sem ela, o grupo não é aprovado e ninguém recebe o certificado do módulo avançado.

Fase 0 — Decisões antes de escrever código

Nada disso é técnico o bastante para uma pessoa decidir sozinha. São quatro decisões, e todas travam trabalho de mais de uma frente.

F0.1 — Quais campos comparar

A decisão mais importante do projeto. Uma apólice D&O tem dezenas de cláusulas; o sistema não precisa extrair todas, precisa extrair as que mudam uma decisão.

Candidatos para a conversa: limite máximo de indenização, franquia (retenção), vigência, âmbito geográfico, definição de segurado, exclusões principais, cobertura para custos de defesa, retroatividade,

prazo complementar.

Quem decide: Paulo Henrique lidera — é corretor, e essa é exatamente a leitura que ele faz no trabalho. O grupo confirma o escopo. **Meta:** 8 a 12 campos. Menos que isso não demonstra comparação; mais vira extração rasa em todos.

F0.2 — Onde conseguir as apólices

O enunciado sugere documentos públicos: modelos publicados por seguradoras, material da SUSEP, cláusulas padrão de mercado. **Precisamos de pelo menos três apólices reais de seguradoras diferentes** — comparar duas versões do mesmo modelo não demonstra nada.

Quem decide: Paulo Henrique indica onde procurar; qualquer um baixa. **Atenção:** a fonte de cada documento tem de ser citada no relatório.

F0.3 — Como ler o documento

Três caminhos, e a escolha muda a frente A inteira:

1. **PDF nativo** (texto embutido) — `pypdf` resolve, é rápido e não custa nada.
2. **PDF escaneado** — exige OCR (Tesseract local, ou serviço de nuvem).
3. **LLM multimodal** — manda a página como imagem e deixa o modelo ler.

Recomendação: tentar o caminho 1 primeiro e cair no OCR só quando a página não tiver texto. A maioria dos modelos públicos de apólice é PDF nativo. Mas **o enunciado exige aceitar imagem**, então o caminho 2 precisa existir nem que seja para um documento.

F0.4 — Onde guardar o que foi extraído

O enunciado pede "armazenamento estruturado" e cita SQL ou NoSQL. Para um MVP, SQLite resolve e não exige subir serviço nenhum.

Recomendação: SQLite. A pergunta a responder no relatório não é "qual banco", é "por que este banco basta para o problema".

As cinco frentes

Frente A — Ingestão e extração de texto

Transformar o arquivo que chega em texto confiável, sabendo de qual página veio cada trecho — sem isso a rastreabilidade da frente B morre.

Tarefa	O que entrega
A.1	Recepção do documento: aceita PDF e imagem, rejeita o resto com mensagem clara
A.2	Extração de PDF nativo, preservando número de página
A.3	OCR para páginas sem texto embutido
A.4	Tolerância a falha: documento corrompido ou página ilegível não derruba o lote

Pronto quando: as três apólices escolhidas em F0.2 viram texto, e cada trecho sabe dizer de que página saiu.

Frente B — Extração das cláusulas (o coração do projeto)

É aqui que a IA Generativa entra de verdade, e é o que o enunciado avalia como "correta utilização de IA Generativa".

Tarefa	O que entrega
B.1	Dicionário dos campos de F0.1: nome, o que significa, como costuma aparecer no texto
B.2	Agente extrator com LLM: recebe o texto, devolve os campos estruturados
B.3	Rastreabilidade: cada campo extraído guarda a página e o trecho de origem
B.4	Validação: campo ausente é <code>null</code> explícito, nunca inventado

Pronto quando: rodando sobre as três apólices, sai uma estrutura preenchida e é possível apontar, para qualquer campo, onde ele estava no documento.

A lição do Desafio 5 aplicada aqui: lá, o guardrail impedia o modelo de citar número que a previsão não tinha. Aqui o risco é maior — um limite de indenização inventado é pior que uma mensagem errada. **B.3 não é enfeite: é o que separa o projeto de um chute bem formatado.**

Frente C — Armazenamento e comparação

Tarefa	O que entrega
C.1	Esquema do banco e gravação das apólices processadas
C.2	Motor de comparação: campo a campo, entre duas ou mais apólices
C.3	Classificação da diferença: igual, diferente, ausente numa delas
C.4	Relatório comparativo em texto, gerado por LLM a partir das diferenças

Pronto quando: dadas duas apólices, sai uma tabela de diferenças e um resumo que explica o que elas significam para quem contrata.

Cuidado com a fronteira: C.2 decide *o que* é diferente (determinístico, testável); C.4 explica *por que importa* (LLM). Misturar os dois foi o erro que custou um PR de consolidação no Desafio 5.

Frente D — Interface e demonstração

Tarefa	O que entrega
D.1	Upload de apólices pela interface
D.2	Visualização lado a lado das diferenças
D.3	Rastreabilidade na tela: clicar num campo e ver de onde ele veio
D.4	Demonstração por linha de comando, para o vídeo não depender da interface

Pronto quando: dá para subir duas apólices e ver a comparação sem tocar no terminal.

Frente E — Documentação, pitch e vídeo

Maior que no Desafio 5, e com dois entregáveis que não são texto.

Tarefa	O que entrega
E.1	README com os seis itens obrigatórios do enunciado
E.2	Relatório técnico com sete seções (duas novas: limitações conhecidas e evolução futura)
E.3	<code>InsurMinds_Projeto_Final.pptx</code> — pitch deck
E.4	<code>InsurMinds_Projeto_Final.mp4</code> — vídeo de até 5 minutos
E.5	ZIP do código e organização da pasta <code>Projeto_Final_Artefatos</code>

Divisão sugerida

Baseada no que cada um demonstrou no Desafio 5. **A Juliana está viajando**, então a frente E foi repartida entre os quatro — ela permanece como representante, responsável pelo envio, e reassume o que fizer sentido quando voltar.

Integrante	Frente	Por quê
Paulo Henrique	F0.1, F0.2, B.1 + conteúdo de negócio do pitch	É o corretor. O dicionário de campos D&O é o <code>regras.yaml</code> deste projeto — a peça que deu ao Desafio 5 seu melhor argumento. E o problema do pitch é a dor que ele vive: horas de especialista comparando cláusulas
Nicole Paes	Frente B (B.2 a B.4)	Entregou os agentes e achou o bug do LLM que se disfarçava de fallback correto
Daniel Ramon	Frentes A e C + E.1, E.5 + consolidação do relatório	Coleta e motor de regras foram suas no Desafio 5, e o README e o empacotamento também
Paulo Roberto	Frente D + E.3 (pitch) + E.4 (vídeo)	Fez a interface e a demonstração; é quem melhor sabe mostrar o sistema funcionando
Juliana Catarina	Envio da entrega	Representante do grupo — a submissão sai obrigatoriamente do e-mail dela

O relatório técnico sem a Juliana

E.2 é a maior peça órfã. Em vez de um dono só, **cada frente escreve a seção que lhe corresponde** e o Daniel consolida:

Seção do relatório	Quem escreve
Arquitetura da solução	Daniel
Tecnologias utilizadas	Daniel
Descrição dos agentes	Nicole (frente B) e Paulo Roberto (frente D)
Fluxo de processamento	Daniel
Justificativa das decisões arquiteturais	quem tomou cada decisão, em uma frase
Limitações conhecidas	todos — cada um sabe onde a própria frente é frágil
Possibilidades de evolução futura	todos

Quando a Juliana voltar, o caminho natural é devolver a ela a revisão e a formatação final do relatório — foi o que ela fez bem no Desafio 5, e é trabalho de fim de ciclo. Se voltar a tempo, o pitch também pode ir para ela, liberando o Paulo Roberto para focar no vídeo. Reavaliar por volta de **27/09**.

Por que o vídeo fica com o Paulo Roberto: gravar exige a aplicação rodando na mão de quem a construiu. Ele monta o pitch e grava; o Paulo Henrique dá o conteúdo do problema de negócio, que é a primeira parte do deck.

Calendário sugerido

Até	O que precisa estar pronto
17/09	Fase 0 fechada. Apólices baixadas, campos definidos, stack escolhida
22/09	Frentes A e B funcionando: documento entra, campos saem estruturados
27/09	Frente C: comparação entre duas apólices gerando saída. Reavaliar o que devolver à Juliana
30/09	Frente D: interface demonstrável. Congelamento de funcionalidades
02/10	Vídeo gravado e pitch pronto
04/10	Relatório final e ZIP. Revisão do grupo
06/10	Entrega — não deixar para este dia

O congelamento em 30/09 não é burocracia: **sem produto estável não há vídeo**, e o vídeo é o entregável mais fácil de perder por falta de tempo.

Riscos conhecidos

1. **O vídeo ficar para o fim.** É o item mais provável de atrasar. Por isso tem dono e data próprios.
1. **Extração alucinada.** Um limite de indenização inventado passa despercebido numa demonstração e destrói a credibilidade numa pergunta. B.3 e B.4 existem contra isso.
1. **Cota do LLM.** Já aconteceu no Desafio 4 e no 5. Processar uma apólice inteira gasta muito mais token que gerar uma mensagem de SMS — **testar o consumo cedo.**
1. **Apólices difíceis.** Se os três documentos forem escaneados e ilegíveis, a frente A vira o gargalo. Por isso F0.2 vem antes de tudo.
1. **Quatro pessoas em vez de cinco.** Com a Juliana viajando, a frente E está repartida e o relatório não tem um dono único. O risco não é a escrita — é ninguém reparar que uma seção ficou sem autor. A tabela de seções acima existe para isso; conferir na revisão de 04/10, e **não contar com o retorno dela** para que a entrega aconteça.